知序智能教学平台

第 6 课项目验证报告：LLM 请求参数、知识库与技能传递范围、MCP 工具集成

仓库地址	https://github.com/xugaopeng0/courseproject-smartteachingwebsite.git
分支 / 提交	main / a5109a6（第 6 课工具接入 ea53a17 + 本轮补齐 a5109a6）
验证时间	2026-10-27
验证方式	透明抓包代理记录真实报文（对话走 DeepSeek，嵌入走本机 Ollama）；工具链路另用确定性替身抓两轮报文

1. 项目简介

面向课程场景的智能教学平台：教师建班、上传讲义、维护提示词与技能；学生在班级内检索讲义、向「解题助手」提问，回答逐块流式返回并给出可核对的原文出处；平台支持内置技能与自定义技能、外部工具与 MCP 服务接入，并记录每一次工具调用。

1.1 技术栈与形态

前端	React 19 + TypeScript + Vite
后端	Go 1.26（标准库 + go-sql-driver/mysql），HTTP JSON API 与 SSE 流式
数据	MySQL 8.4（ngram 全文索引）+ Qdrant（余弦向量检索）
模型通道	OpenAI 兼容接口；嵌入与对话可分别指向不同服务，密钥只在服务端
工具服务	mcp-server/：自建 MCP 服务（JSON-RPC 2.0，initialize / tools/list / tools/call）
部署	Docker Compose：db / qdrant / api / worker / web / mcp-demo

1.2 五项必备功能的落地

内置多个 AI 应用	三个：知识库问答（单次）、解题助手（会话、流式）、出题练习（单次，任务模板不同）；共用检索与出处管线
提示词模板	平台默认 + 班级覆盖；支持 {{question}} 等变量；固定约束、班级要求、技能正文、材料片段四段式组装
知识库检索	关键字 / 向量 / 混合三模式，按班级隔离；提问前先检索，只取前 4 条切片
内置 Skill 与上传技能	内置「解题引导」；可新增班级技能，也可上传 .md（front-matter）/ .json 技能文件
外部工具与 MCP	登记并连接 MCP 服务 → 发现工具 → 绑定技能 → 对话中由模型自主调用 → 记录调用

2. Git 仓库地址

```
https://github.com/xugaopeng0/courseproject-smartteachingwebsite.git
```

3. 验证方法

为了回答「到底传了什么」，本报告不依赖代码推断，而是在应用与真实模型之间插入一个透明记录代理：请求原样转发上游，同时把完整请求体与响应体写入日志。

```
api 容器 → capture proxy(/deepseek/v1) → https://api.deepseek.com/v1
                  └ 记录 model / stream / messages / tools 等完整报文
api 容器 → capture proxy(/ollama/v1)   → http://127.0.0.1:11434/v1
```

对话模型 deepseek-flash（真实云端）；嵌入模型 qwen3-embedding:0.6b（本机 Ollama）。场景 A/B/C 由脚本驱动真实接口完成。

4. 逐题验证

4.1 每次对话传给 LLM 的参数；提示词模板是否一并传递

结论：每次对话是 POST /chat/completions，请求体包含 model、messages、stream，绑定工具时再加 tools 与 tool_choice。提示词模板会一并传递——它以 system 消息的正文发送，而不是服务端隐式指令。

model	deepseek-flash

stream	True
messages	2 条：system → user
system 长度	263 字（A 场景）；绑定技能后 557 字
tools	formula_hint
其他参数	未设置 temperature / top_p，使用服务端默认值

场景 A 实际发送的 system 消息（原文）：

```
约束：只依据下面「材料」小节的内容回答，不得使用你自己的知识补充；材料没有覆盖的问题，回答「资料中未找到相关内容」；回答保留材料编号 [n]。

班级要求：你是班级学习助手。只依据下面提供的本班材料回答：材料不足时直接说明未找到相关内容，不要用自己的知识补充；回答使用简体中文，先给结论再给依据，并保留材料编号 [n]。
```

4.1.1 返回内容是什么

非流式（知识库问答/出题练习）返回 JSON：choices[0].message.content 为正文，finish_reason 为结束原因，usage 给出 token 用量；流式（解题助手）返回 SSE，每行 data: 是一个增量块，delta.content 为正文片段，最后以 data: [DONE] 结束。

非流式返回（实测，出题练习）：


```
{
  "id": "5a3961b0-c55c-433d-982f-3b27f1e9ccd7",
  "object": "chat.completion",
  "model": "deepseek-flash",
  "finish_reason": "stop",
  "message_role": "assistant",
  "content_head": "技能标记-ZX7Q  \n 结论：材料足以围绕“考核方式与作业要求”出 3 道由易到难的练习题；按“解题引导”技能，以下不直接公布最终答案，只提供解题思路与自查方法。\n\n1. **练习题（易）**：根据材料，期末项目成绩占总成绩的比例是多少？期末项目小组人数范围是多少？ \n  **参考思路（非最终答案）**：在 [2] 的“成绩构成”中找“期末项目占”的百分比，再在“期末项目以小组为单位提交”后找人数范围；注意不要和“平时作业占”的比例混淆。 \n**用到的材料**：[2]\n\n2. **练习题（中）**：期末项目需要提交哪些材料？其中设计报告页数上限和提交截止时间分别是什么？ \n  ",
  "usage": {
    "prompt_tokens": 1408,
    "completion_tokens": 2010,
    "total_tokens": 3418,
    "prompt_tokens_details": {
      "cached_tokens": 128
    },
    "completion_tokens_details": {
      "reasoning_tokens": 1601
    },
    "prompt_cache_hit_tokens": 128,
```

```
    "prompt_cache_miss_tokens": 1280
  }
}
```


流式返回（实测，DeepSeek 增量块）：


```
data: {"id":"7327d4f3-8344-4838-a469-
aeb502bc699e","object":"chat.completion.chunk","created":1793085840,"model":"deepseek-
flash","system_fingerprint":"e72d3c7f663d3e1383b00b3884cb4501","choices":[{"index":0,"delta":
{"role":"assistant","content":null,"reasoning_content":""},"logprobs":null,"finish_reason":null}]}
```


4.2 绑定知识库后，是否把知识库全部内容传给 LLM

结论：不会。每次提问先做本班混合检索，只取前 4 条切片放进 user 消息的「材料片段」，其余内容不发送；没有命中时不调用模型，直接返回固定文案。

本次实验班级讲义总量	2057 字（4 份讲义）
单次请求携带的材料	1650 字，编号 [1]–[4]，最多 4 条切片
上限来源	retrieveAnswerContext 取混合检索前 4 条； buildAnswerMessages 只拼接命中切片
无命中	不调用对话模型（no_matches 短路），对话请求数 +0

材料在报文中的实际形状（节选）：

```
材料片段：
[1] 材料：课程考核办法（第 1 片，第 1–533 字）
# 课程考核办法
## 成绩构成
平时作业占 40%，期末项目占 60%
…

问题：期末项目和平时作业各占多少比例？
```

因此「绑定知识库」不等于把知识库塞进上下文：讲义规模越大，单次请求携带的仍是 4 条切片。

4.3 绑定技能后，请求里是否包含该技能的全部内容

结论：包含全部正文。启用中的技能正文整段拼进 system 消息（形如「技能「名称」：正文」），不做截断（仅受 2000 字上限约束）；停用的技能不出现，班级正文为空时沿用平台同名技能。

技能正文长度	283 字（含唯一标记 技能标记-ZX7Q）
system 中该段长度	283 字
是否完整	是，字符数与原文一致
注入位置	system 消息末尾：固定约束 → 班级要求 → 技能正文

实际 system 消息（场景 B，节选）：

约束：只依据下面「材料」小节的内容回答，不得使用你自己的知识补充；材料没有覆盖的问题，回答「资料中未找到相关内容」；回答保留材料编号 [n]。

班级要求：你是班级学习助手。只依据下面提供的本班材料回答：材料不足时直接说明未找到相关内容，不要用自己的知识补充；回答使用简体中文，先给结论再给依据，并保留材料编号 [n]。

技能「解题引导」：只做解题引导：说明思路、给出下一步可以尝试的步骤，必要时提出追问，帮助学生自己想出答案。不要直接给出最终答案、完整解答或可直接提交的结果；即使学生要求公布答案，也只提供思路与自查方法。

技能「证据技能」：技能标记-ZX7Q 回答时先给一句话结论，再分点列出依据，最后给出一个可以自查的问题。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内容用于验证技能正文是否被完整传递。这段内

…（后略）

4.4 执行具体技能时，执行逻辑是什么

结论：技能有两种执行方式，取决于是否声明了工具。

（1）提示词型技能（只有正文）：不产生额外模型调用，正文在组装阶段整段进入 system，由模型生成时遵守——即 4.3 的形态。

（2）工具型技能（正文 + tools）：走宿主编排循环，模型决定是否调用，宿主执行与净化：

① 候选集	生效且启用的技能工具项 → 去掉内置检索 → 只保留本班所有者、已连接、在发现清单内的工具 → 去重 → 上限 4
② 声明	候选工具以 OpenAI tools 形式随请求发出，tool_choice=auto
③ 决策	模型返回 delta.tool_calls（工具名 + 参数 JSON 字符串）
④ 校验	宿主按同一份 JSON Schema 子集校验参数；不合法记为「被拒」且不发起调用
⑤ 执行	带 Bearer 令牌 POST tools/call 到 MCP 服务，超时 8 秒
⑥ 净化	按句丢弃指令式语句、超长截断到 1200 字；结果只以 role=tool 回传，不进入 system
⑦ 收尾	追加 assistant(tool_calls) 与 tool 消息后再次请求模型，由模型组织最终回答
⑧ 上限	轮次上限 3、累计调用上限 4（可配置）；超限不再声明工具，用已有信息作答，不报错中断
⑨ 可观测	调用事件先于正文推送，结束元数据带工具状态；每次调用写一条只增不改的记录

实证（确定性抓包）：第 1 轮 roles=[system,user] 并声明 tools，响应要求调用；第 2 轮 roles=[system,user,assistant,tool]：

```
{
  "role": "assistant",
  "tool_calls": [
    {
      "id": "call_stub_1",
      "name": "formula_hint",
      "arguments": "{\"topic\":\"总评计算\"}"
    }
  ]
}
```

tool 消息（净化后的工具结果，161 字）节选：

```
主题：总评计算（入门） 公式：总评 = 平时作业得分 × 40% + 期末项目得分 × 60% 符号：40% 与 60% 是两项权重，二者相加为 1；两个得分都按满分 100 计。 下一步：先把两项得分分别乘以权重，再把两个结果相加；最后按题目要求决定是否取整。 提示：先把已知量抄成一行，再逐个标上单位，能减少代错位置
```

4.5 集成 MCP 工具后，每次请求传给 LLM 的参数

结论：与 4.1 相同的报文，另加 tools（工具名、说明、JSON Schema 输入结构）与 tool_choice；工具执行后的下一轮请求，messages 里多出 assistant 的 tool_calls 与 role=tool 的结果消息。

实测请求体中的 tools（真实抓包，来自 mcp-demo 的 formula_hint）：

```
[
  {
    "type": "function",
    "function": {
      "name": "formula_hint",
      "description": "formula_hint（来自 campus-tools）当学生询问某个公式的构成、符号含义或解题思路时使用（教学场景）。只给出公式、符号解释与可自行尝试的下一步，不做数值代入、不给最终数值答案。不适用于查课程政策、讲义检索、非计算类问题；需要数值结果时应由学生自己代入计算。",
      "parameters": {
        "properties": {
          "level": {
            "enum": [
              "beginner",
              "intermediate",
              "advanced"
            ],
            "type": "string"
          },
          "topic": {
            "maxLength": 200,
            "minLength": 1,
            "type": "string"
          }
        },
        "required": [
          "topic"
        ],
        "type": "object"
      }
    }
  }
]
```

每轮新增字段	tools（数组）、tool_choice（auto）
第 2 轮新增消息	assistant：tool_calls=[{id, type: function, function: {name, arguments}}]；tool：tool_call_id + 净化后文本
未声明工具时	请求与 4.1 完全一致（tools 字段不出现）

被拒情形	未连接、越权或不在候选集内：不发起 tools/call，记一条 rejected

4.6 提示词模板的变量机制

模板里的 {{question}}、{{class_name}}、{{skill_names}}、{{date}} 在组装时被替换，未识别的占位符原样保留（便于发现拼写错误）。会话与单次问答使用同一套渲染规则；班级与平台提示词都能用。

```
{{class_name}} 的 {{question}} 由谁负责?
→ 渲染后：软件工程 2026 班的 考核占比 由谁负责?
```

可用变量	{{question}}（本次提问）、{{class_name}}、{{skill_names}}、{{date}}
渲染时机	服务端组装 system 提示词之前
未知变量	原样保留，不报错
实测	quiz 模板里的 {{question}} 被替换为本次提问（TestAppsListAndQuizTemplate）

4.7 上传技能的执行方式

上传的技能与表单创建的技能完全等价：解析（.md 的 front-matter 或 .json）→ 校验名称/正文/工具 → 入库（同班级同名覆盖）→ 进入与 4.3/4.4 相同的注入与编排路径。

支持格式	.md（可选 front-matter：name / enabled / tools）、.json（{name, body, enabled, tools}）
大小上限	32 KB（超过 413）
校验	与表单保存同一套：名称规则、正文 1–2000 字、工具格式/归属/连接/清单
实测	.md 与 .json 均 201；.exe 400；front-matter 未闭合 400；工具未连接 400（TestSkillImport）

5. 验收证据汇总

后端测试	go vet 0；后端全量测试 ok 192.9s（含真实 MySQL +

	Qdrant）
接口测试套件	apitest 对 Compose 部署 17/17 通过（含应用清单、技能上传、端到端工具链路）
工具服务验收	17/17：健康检查、能力协商、工具发现、两个工具执行、四类协议错误码、无令牌 401、通知 202、非 POST 405、响应无令牌
令牌边界	镜像内检索令牌字面值 0 命中；宿主接口只回 has_token；令牌只在服务端环境变量与加密列
界面验收	10/10（真实浏览器）：工具服务、技能工具项、会话工具步骤、调用记录、断开后保存被拒、应用选择器、出题练习、模板变量提示、技能文件上传、无脚本错误
其他	73 项 HTTP 集成、前端构建、OpenSpec 19/19 校验均通过

6. 验证过程中发现并修复的问题

- 候选集跨教师串用（本轮新发现，已修复并提交 a5109a6）：工具服务名只在所有者内唯一，候选集原先按名称查找，会命中另一位教师的同名服务器，导致工具调用与记录落到他人范围。已改为按班级所有者过滤，并补回归测试 TestCandidateToolsScopedToClassOwner。
- 调用记录写入边界：被拒调用在服务器已不存在时原先无法写入；已区分「未知归属」与「归属失效」，前者如实记录、后者按规格跳过。
- 抓包方法学：DeepSeek 响应为 gzip，首轮抓包曾把压缩字节当文本；已在代理内按 content-encoding 解压后再记录（转发仍用原始字节）。

7. 局限与说明

- 真实模型（deepseek-flash）在带 tools 的 7 次请求中没有选择调用工具；同一套编排在替身下稳定触发，并在 apitest 与界面验收中跑通过真实模型的成功路径。因此 4.4/4.5 的两轮报文取自替身，仅替换模型输出，编排代码不变。
- 「知识库只取前 4 条」是产品设定（控制上下文成本）；实验班级规模较小，材料约占讲义总量八成，讲义越多该比例越低。
- 技能正文整段注入、上限 2000 字；超出保存会被拒绝，不会截断成半段。
- 令牌轮换需重启服务（令牌在启动时读取）。

附录 A 复现步骤

```
docker compose up -d
node .local/llm-capture.mjs
docker compose -f compose.yaml -f .local/compose-capture.yaml up -d api worker
node .local/capture-scenarios.mjs && node .local/capture-analysis.mjs
node .local/capture-tool-rounds.mjs
$env:APITEST_BASE_URL='http://localhost:8080'; npm run test:api
node .local/tool-ui-check.mjs
```